

MASKE TESPİTİ PROJE RAPORU

1. Kullanılan Model Mimarisi

Bu projede temel model olarak **MobileNetV2** mimarisi tercih edilmiştir. MobileNetV2, **ImageNet** veri seti üzerinde önceden eğitilmiş, hafif ve verimli bir konvolüsyonel sinir ağıdır. Bu model, sınırlı hesaplama gücüne sahip cihazlarda bile yüksek performans gösterebilmesiyle bilinir ve transfer learning (transfer öğrenme) için oldukça uygundur.

Modelin orijinal yapısında son katmanlar (fully connected ve sınıflandırma katmanları) çıkarılarak, bu temel üzerinde yeni ve projenin ihtiyacına uygun katmanlar eklenmiştir. Bu sayede model, kendi veri setimize özgü sınıflandırmayı daha iyi yapabilmektedir.

Yeni eklenen katmanlar şunlardır:

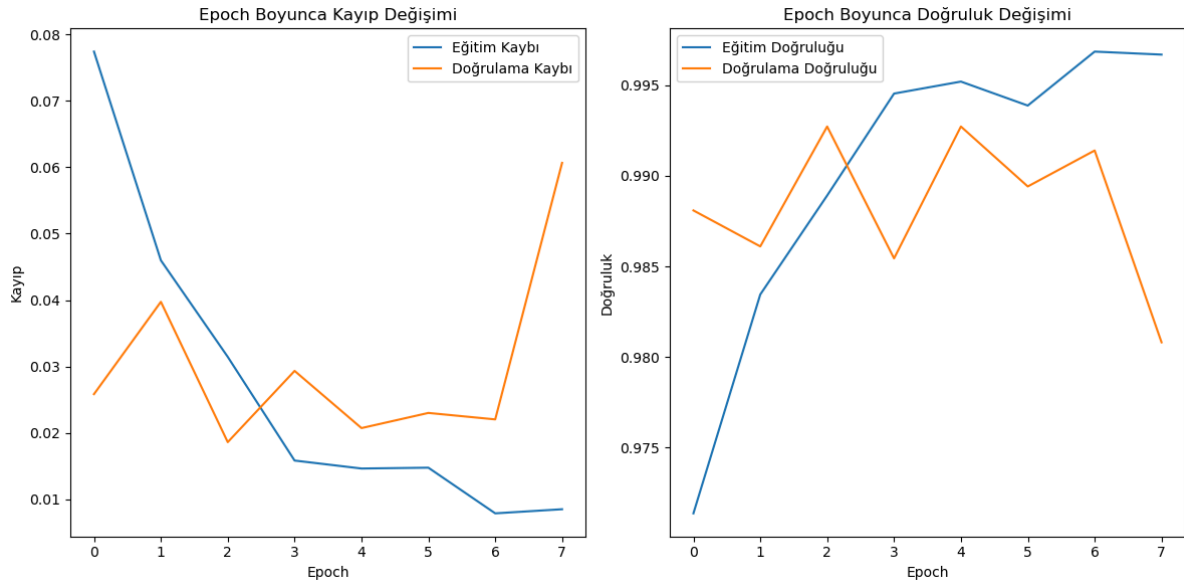
- **GlobalAveragePooling2D:**
Bu katman, konvolüsyonel katmanlardan gelen çok boyutlu özellik haritalarını tek bir vektöre indirger. Böylece modelin parametre sayısı azalır ve aşırı öğrenme (overfitting) riski düşer. Ayrıca modelin farklı giriş boyutlarını işleyebilmesine olanak sağlar.
- **256 Nöronlu Dense Katman (ReLU aktivasyonlu):**
Bu tam bağlı katman, elde edilen özniteliklerin öğrenilmesini derinleştirir ve modelin karmaşık ilişkileri yakalamasına yardımcı olur. ReLU aktivasyonu, doğrusal olmayan ilişkileri modellemek için kullanılır ve eğitim sırasında hızlı ve etkili öğrenmeyi sağlar.
- **%50 Dropout Katmanı:**
Dropout, modelin aşırı öğrenmesini önlemek için kullanılan etkili bir düzenleme (regularization) yöntemidir. Eğitim sırasında rastgele %50 oranında nöronları devre dışı bırakarak, modelin farklı nöronlara daha bağımsız öğrenme yapmasını sağlar ve genelleme kabiliyetini artırır.
- **1 Nöronlu Sigmoid Aktivasyonlu Dense Katman:**
Son katman olarak tek nöronlu bir Dense katman eklenmiştir. Sigmoid aktivasyonu kullanılarak, model çıktı olarak 0 ile 1 arasında bir değer üretir. Bu sayede ikili (binary) sınıflandırma problemi çözülür; örneğin "maske var" veya "maske yok" şeklinde sonuç verir.

Eğitim başlangıcında **MobileNetV2'nin temel (önceden eğitilmiş) katmanları dondurulmuştur (freeze edilmiştir)**. Böylece bu katmanların ağırlıkları değiştirilmez ve ImageNet'ten öğrenilen güçlü özellikler korunur. Yalnızca son eklenen katmanlar eğitilerek model, yeni veri setine özgü ayrımları öğrenir. Bu yöntem, daha hızlı eğitim ve daha az veriye iyi performans elde etmek için yaygın olarak tercih edilir.

2. Eğitim Süreci ve Metrikler

- Toplam 30 epoch planlandı, ancak **erken durdurma (early stopping)** uygulanarak 8. epochda eğitim durduruldu.
- Eğitim esnasında model hızla iyileşti; 3. epochda en iyi doğrulama kaybı (val_loss) elde edildi ve eğitim sonrasında bu epochun ağırlıkları geri yüklendi.
- Son epochlarda eğitim doğruluğu %99.81'e kadar çıktı, doğrulama doğruluğu ise %98.08 ile %99.27 arasında değişti.
- Sonuçta model %99.27 doğruluk ile eğitimini tamamladı.

```
Epoch 3/30
189/189 — 118s 627ms/step - accuracy: 0.9895 - loss: 0.0311 - val_accuracy: 0.9927 - val_loss: 0.0186
Epoch 4/30
189/189 — 119s 631ms/step - accuracy: 0.9942 - loss: 0.0175 - val_accuracy: 0.9854 - val_loss: 0.0293
Epoch 5/30
189/189 — 118s 623ms/step - accuracy: 0.9947 - loss: 0.0154 - val_accuracy: 0.9927 - val_loss: 0.0207
Epoch 6/30
189/189 — 117s 622ms/step - accuracy: 0.9940 - loss: 0.0140 - val_accuracy: 0.9894 - val_loss: 0.0230
Epoch 7/30
189/189 — 118s 624ms/step - accuracy: 0.9971 - loss: 0.0083 - val_accuracy: 0.9914 - val_loss: 0.0220
Epoch 8/30
189/189 — 117s 620ms/step - accuracy: 0.9981 - loss: 0.0054 - val_accuracy: 0.9808 - val_loss: 0.0606
Epoch 8: early stopping
Restoring model weights from the end of the best epoch: 3.
48/48 — 26s 522ms/step
```



Epoch 1'de, model %79.57 doğruluk ve 0.4790 kayıp ile eğitimine başladı. Bu başlangıç değeri, modelin temel özellikleri öğrenmeye yeni başladığını gösteriyor.

İlk epochun sonunda eğitim doğruluğu hızla %94.18'e çıkarken, kayıp da 0.1461'e düştü. Doğrulama doğruluğu ise %98.81 ile çok yüksek ve kayıp değeri 0.0258 ile düşük kaldı. Bu, modelin henüz aşırı öğrenme yapmadığını ve genel olarak iyi genelleme sağladığını gösteriyor.

Epoch 2 ve 3'te, eğitim doğruluğu sırasıyla %98 ve %98.95'e ulaşırken kayıp hızla azaldı (0.0518 ve 0.0311). Aynı zamanda doğrulama doğruluğu %98.61'den %99.27'ye yükseldi, doğrulama kaybı ise 0.0397'den 0.0186'ya düştü. Bu dönemde model hem eğitim hem de doğrulama verisinde oldukça başarılı oldu.

Epoch 4 ila 7 arası, eğitim doğruluğu %99 ve üzeri seviyelerde seyretti, kayıp ise çok düşük değerlere indi (0.0175'den 0.0083'e kadar). Doğrulama doğruluğu ise dalgalansa da genel olarak %98 - %99 aralığında yüksek kaldı.

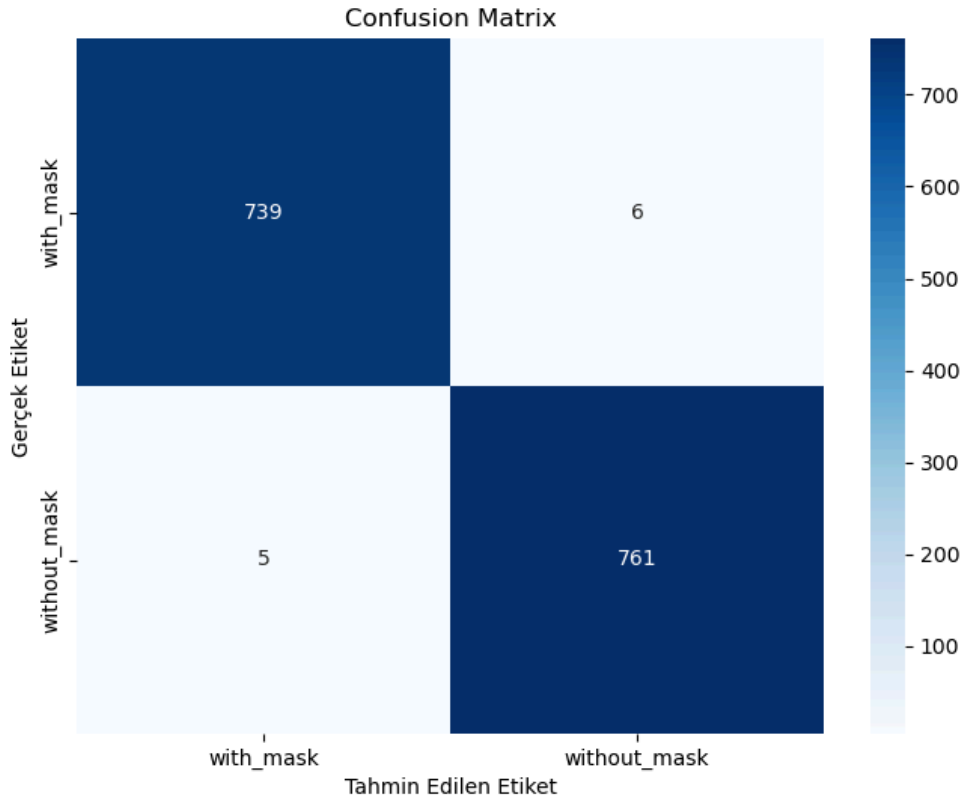
Bu süreçte modelin öğrenmeye devam ettiği, ancak doğrulama kaybının dalgalanmasıyla hafif bir aşırı öğrenme (overfitting) sinyali başlayabileceği gözlemleniyor.

Epoch 8'de, eğitim doğruluğu %99.81 gibi çok yüksek bir seviyeye çıkarken, doğrulama doğruluğu %98.08'e geriledi ve doğrulama kaybı 0.0606 ile yükseldi. Bu doğrulama kaybındaki artış, modelin doğrulama setine karşı aşırı uyum sağlama (overfitting) belirtisi.

Bu nedenle **erken durdurma (early stopping)** tetiklendi ve eğitim 8. epochda durduruldu. Model, en iyi doğrulama performansını gösterdiği 3. epoch ağırlıkları ile geri yüklendi.

3. Confusion Matrix ve Yorum

Confusion matrix aşağıdaki gibidir:



True Positives (TP): Model, gerçekten “with_mask” olan 745 örnekten 739’unu doğru sınıflandırdı.

False Negatives (FN): 6 örneği “with_mask” olmasına rağmen “without_mask” olarak yanlış tahmin etti.

False Positives (FP): Model “without_mask” olan 766 örnekten 5’ini yanlışlıkla “with_mask” olarak sınıflandırdı.

True Negatives (TN): 761 örnek doğru şekilde “without_mask” olarak sınıflandırıldı.

Precision (Kesinlik)

- with_mask için Precision:** $TP / (TP + FP) = 739 / (739 + 5) \approx \%99.32$
Yani model, “with_mask” tahminlerinin %99.32’si gerçekten doğru.
- without_mask için Precision:** $TN / (TN + FN)$ bu matris için genelde negatif sınıf precision olarak hesaplanmaz ama genel olarak sınıf bazlı raporda %99’un üzerinde.

Recall (Duyarlılık)

- with_mask için Recall:** $TP / (TP + FN) = 739 / (739 + 6) \approx \%99.79$
Model “with_mask” olanların %98.79’unu doğru yakalıyor.

- **without_mask için Recall:** $TN / (TN + FP) \approx \%99.35$
Model “without_mask” olanların %99.35’ini doğru tahmin ediyor.

F1-Score (F1-Skoru)

with_mask için:

$$2 * (Precision * Recall) / (Precision + Recall) = \\ 2 * (0.9932 * 0.9920) / (0.9932 + 0.9920) \approx \%99.26$$

without_mask için F1 skoru, precision ve recall değerlerinin yüksek olması sebebiyle yaklaşık %99 civarındadır.

Yorum

Yanlış Negatiflerin (FN) az olması, özellikle “with_mask” olan bir kişinin maskesiz olarak algılanma riskinin çok düşük olduğunu gösterir. Bu, güvenlik açısından önemli, çünkü maskesiz kişinin maske takıyor gibi algılanması daha az sorun yaratır.

Yanlış Pozitiflerin (FP) azlığı ise maskesiz kişilerin maskeli olarak yanlış sınıflandırılmasının da çok nadir olduğunu gösterir.

Genel olarak model, iki sınıf arasındaki ayrımı çok başarılı yapıyor ve hem hatalı pozitif hem de hatalı negatif oranları oldukça düşük.


Bu durum modelin gerçek dünyada maske takıp takmadığını yüksek doğrulukla ayırt edebileceğine işaret eder.

4. Görsel Tahmin Sonuçları

Model rastgele seçilen 5 örnek görsel üzerinde test edildi:

- Tahmin edilen etiketler ve gerçek etiketler karşılaştırıldı.
- Tahminler doğru olanlar yeşil başlıkla, yanlış olanlar kırmızı başlıkla gösterildi.
- Test edilen tüm 5 örnek için modelin **doğru tahmin yaptığı** gözlemlendi.
- Bu durum modelin görsel sınıflandırmada yüksek başarı ve güvenilirlik sağladığını destekliyor.

Gerçek: without_mask | Tahmin: without_mask (1.00)



Gerçek: with_mask | Tahmin: with_mask (0.00)



Gerçek: with_mask | Tahmin: with_mask (0.00)



Gerçek: with_mask | Tahmin: with_mask (0.00)



Gerçek: with_mask | Tahmin: with_mask (0.00)



5. Karşılaşılan Zorluklar ve Çözüm Yolları

- **Veri çeşitliliği:** Görseller farklı aydınlatma ve pozisyonlarda olduğundan model zaman zaman zorlandı. Bu yüzden eğitim sırasında veri artırma (augmentation) teknikleri kullanıldı (dönme, kaydırma, zoom vb.).
- **Overfitting riski:** Model yüksek doğruluk gösterirken overfitting olmaması için dropout katmanı eklendi ve erken durdurma uygulandı.
- **Veri kalitesi:** Bazı görsellerde transparan renk paletleri ve düşük kalite uyarıları alındı.